

Regresión Logística

Análisis de Abandono de Clientes Bancarios

10,000 Clientes

14 Variables

Modelación



**Churn
Prediction**

Contenido de la Presentación

01

Planteamiento del Problema

Descripción del fenómeno de churn bancario

02

Datos y Variables

Dataset, EDA univariado y bivariado

03

Modelo 1 - Base

Coeficientes · Ajuste · Validación

04

Modelo 2 - Recodificado

Coeficientes · Ajuste · Validación

05

Modelo 3 - Final

Coeficientes · Ajuste · Validación - Interacción + Age^2

06

Comparativa & Conclusiones

Hallazgos · Recomendaciones

01 | Planteamiento del Problema

20.37%

de los clientes
abandonaron

7,963 Permanecen

2,037 Abandonan

Desbalance 4:1

¿Por qué importa?

- Retener a un cliente existente cuesta 5-7× menos que adquirir uno nuevo.
- Un modelo predictivo permite identificar el riesgo de abandono antes de que ocurra.
- La regresión logística ofrece coeficientes interpretables que guían estrategias de retención.

Objetivo

Construir y comparar modelos de regresión logística que expliquen y predigan el abandono de clientes de un banco, identificando los factores demográficos y de comportamiento con mayor capacidad discriminante.

02 | Datos y Variables del Modelo

Datos: Conjunto de datos del sector bancario
Tamaño del data set: 10,000 observaciones (14 variables)

Variables del Dataset

CreditScore	Numérica continua
Geography	Categórica (3 países)
Gender	Categórica binaria
Age	Numérica continua
Tenure	Discreta (0-10)
Balance	Numérica continua
NumOfProducts	Discreta (1-4)
HasCrCard	Binaria
IsActiveMember	Binaria
EstimatedSalary	Numérica continua
Exited ★	Respuesta binaria


Distribución de Exited



- La variable de respuesta será: Exited con un enfoque en explicar el abandono de los clientes.
- Las columnas RowNumber, CustomerId & Surname son **identificadores**. No son útiles para explicar el abandono.

Análisis Univariado

Distribución de Variables Numéricas



Score Crediticio: Forma casi simétrica y cercana a una distribución normal.

Age: Distribución asimétrica hacia la derecha. Media ligeramente superior a la mediana . La mayoría de los clientes se ubican entre 30 y 45 años.

Tenure: Distribución uniforme, con asimetría y curtosis.

Balance: Severa acumulación de observaciones en el valor cero, seguido de una distribución aproximadamente unimodal de clientes con saldos positivos.

EstimatedSalary: Distribución uniforme en todo su rango.

Análisis Univariado


Variables categóricas

Tabla de Frecuencias

Variable Predictora	Categoría / Nivel	Frecuencia Absoluta (N)	Frecuencia Relativa (%)	Interpretación / Nota de Negocio
Geography (País)	Francia	5,014	50.14%	El mercado francés concentra la mitad de la muestra; Alemania y España se reparten equitativamente el resto.
	Alemania	2,509	25.09%	
	España	2,477	24.77%	
Gender (Género)	Masculino (Male)	5,457	54.57%	Distribución balanceada, con una ligera mayoría de usuarios hombres.
	Femenino (Female)	4,543	45.43%	
HasCrCard (Posee Tarjeta)	Sí (1)	7,055	70.55%	Alta tasa de bancarización interna: 7 de cada 10 clientes cuentan con tarjeta de crédito física
	No (0)	2,945	29.45%	
IsActiveMember (Miembro Activo)	Sí (1)	5,151	51.51%	Muestra perfectamente equilibrada entre usuarios comprometidos e inactivos operacionalmente
	No (0)	4,849	48.49%	
NumOfProducts (Productos contratados)	1 Producto	5,084	50.84%	Punto crítico: El 96.74% de los clientes se limitan a 1 o 2 productos. Los portafolios multi-producto (3 o más) son marginales.
	2 Productos	4,590	45.90%	
	3 Productos	266	2.66%	
	4 Productos	60	0.60%	

Análisis Bivariado y Multivariado

Variables Numéricas por Categoría de Exited



Edad: Separación evidente. Mayor abandono al incrementar la edad.

Balance: Ligeras diferencias entre grupos. Considerando el fenómeno de observaciones con saldo igual a 0, podría haber información para discriminar y explicar en el abandono.



Score crediticio: Similares ambas categorías

Salario estimado: Similares ambas categorías

Antigüedad: Ligeras diferencias en cuantiles, sin separación.

Análisis Bivariado y Multivariado


Variables categóricas




Análisis Bivariado y Multivariado

Variables categóricas

Proporción de Exited por HasCrCard




Proporción de Exited por IsActiveMember



Análisis Bivariado y Multivariado




Variables categóricas



02 | Datos y Variables del Modelo

Análisis Bivariado y Multivariado


Variables categóricas



- El EDA mostró una concentración de personas que permanecen con un saldo igual a cero en su cuenta.
- Al agrupar clientes con saldo igual a 0 y diferentes de 0, se observa la tasa de abandono para clientes sin saldo del ~13.82% respecto a clientes con saldo ~24%
- Se planteó una nueva variable “Balance_Zero” (‘1’ == saldo 0, ‘0’)

Análisis Bivariado y Multivariado

Correlaciones - Multicolinealidad



- Las correlaciones entre los predictores son demasiado bajas, lo que sugiere que no se anticipan problemas severos de multicolinealidad.
- Gráficos de dispersión no muestran patrones lineales evidentes, ni agrupamientos diferenciados por las categorías de Exited,
- Age es la excepción.

02 | Datos y Variables del Modelo

Variables incluidas

Age

Mayor discriminación en boxplot; mayor edad → mayor abandono

Geography

Diferencias claras por país (Alemania doble riesgo)

Gender

Mujeres con ~9 pp más de abandono

IsActiveMember

Clientes no activos: 2× mayor riesgo

NumOfProducts

Patrón no lineal confirmado (se trata como factor)

Balance / Balance_Zero

Dos poblaciones: indicadora capta mejor el patrón

Variables excluidas (baja capacidad discriminante)

CreditScore · EstimatedSalary · Tenure · HasCrCard → distribuciones similares entre clases (diferencias visuales mínimas en boxplots y barras)

Transformaciones clave

NumOfProducts → Factor

La relación con el abandono no es lineal: 2 prod. = mínimo riesgo & 3-4 prod. = máximo riesgo. Tratarla como numérica induciría una tendencia lineal inexistente.

NumProducts_3M (1 / 2 / 3+)

Agrupación de categorías 3 y 4 (< 2% c/u) para resolver separación completa en el Modelo 1 ($\beta=16.33$, $SE=175.47$). Tasa combinada 85.9% vs 18.2% para 1-2 prod.

Balance_Zero (0/1)

Clientes con Balance=0 presentan tasa de abandono 13.8% vs 24.1% para saldo positivo. Variable indicadora captura esa discontinuidad mejor que Balance continuo.

Age²

Prueba Box-Tidwell: desviación significativa de linealidad ($t=-10.6$, $p<0.001$). Término cuadrático resuelve la no linealidad: riesgo pico a los ~59 años.

03 | Tres Modelos Propuestos

M1	Modelo Base Age + Gender + Geography + IsActiveMember + NumOfProducts Separación cuasi-completa en NumOfProducts=4 (SE=175). Estimaciones inestables.	AIC 7,458.8	AUROC 0.833	⚠ Inestabilidad
M2	Productos Recodificados Age + Gender + Geography + IsActiveMember + NumProducts_3M (1 2 3+) Resuelve la separación completa. Coeficientes estables e interpretables.	AIC 7,474.3	AUROC 0.833	✓ Estable
M3	Con Interacción Age^2 + Gender + Geography + IsActiveMember + NumProducts_3M × Balance_Zero Captura que el efecto del portafolio depende del saldo. Mejor ajuste.	AIC 7,081.5	AUROC 0.8518	★ Modelo Final

03 MODELO 1 — BASE

$$\text{logit}(P) = \beta_0 + \beta_1\text{Age} + \beta_2\text{Gender} + \beta_3\text{Geography} + \beta_4\text{IsActiveMember} + \beta_5\text{NumOfProducts}$$

Coeficientes y Odds Ratios

Variable	β	OR	Sig.
Age	0.071	1.074	***
Gender (Male)	-0.525	0.591	***
Geography (Germany)	0.915	2.498	***
Geography (Spain)	0.060	1.062	n.s.
IsActiveMember (Sí)	-1.105	0.331	***
NumOfProducts 2	-1.521	0.218	***
NumOfProducts 3	2.584	13.256	***
NumOfProducts 4	16.334	—	⚠

⚠ NumOfProducts=4: separación completa (60 obs.). β y SE no confiables.

Métricas de Ajuste

AIC	7,459
Devianza	7,441
LogLik	-3,720
vs Nulo (χ^2)	2,669 ***


Clasificación (umbral 0.5)

Exactitud	84.05%
Sensibilidad	38.00%
Especificidad	95.83%
AUROC	0.833







Validación: Sin multicolinealidad (VIF < 1.1 en todos los predictores). Distancia de Cook < 0.005 en todas las observaciones; sin puntos altamente influyentes. Desviación significativa de linealidad en Age (Box-Tidwell: $\lambda = -0.174$, $p < 0.001$), aunque inspección gráfica sugiere tendencia aproximadamente lineal.

03 MODELO 1 — BASE

$$\text{logit}(P) = \beta_0 + \beta_1 \text{Age} + \beta_2 \text{Gender} + \beta_3 \text{Geography} + \beta_4 \text{IsActiveMember} + \beta_5 \text{NumOfProducts}$$



	Df	Deviance	Resid. Df	Resid. Dev
NULL			9999	10109.8
Age	1	758.73	9998	9351.1
Gender	1	106.21	9997	9244.8
Geography	2	256.53	9995	8988.3
IsActiveMember	1	376.40	9994	8611.9
NumProducts_3M	2	1153.62	9992	7458.3



04 MODELO 2 — RECODIFICADO

$$\text{logit}(P) = \beta_0 + \beta_1\text{Age} + \beta_2\text{Gender} + \beta_3\text{Geography} + \beta_4\text{IsActiveMember} + \beta_5\text{NumProducts_3M}$$

Se agruparon las categorías 3 y 4 en '3+', cuya tasa combinada de abandono es 85.9% —claramente separada de 1 y 2 productos (~18%).

Coeficientes y Odds Ratios

Variable	β	OR	Sig.
Age	0.071	1.074	***
Gender (Male)	-0.527	0.590	***
Geography (Germany)	0.913	2.492	***
Geography (Spain)	0.053	1.054	n.s.
IsActiveMember (Sí)	-1.103	0.332	***
NumProducts_3M 2	-1.521	0.218	***
NumProducts_3M 3+	2.815	16.701	***

Resultado: La recodificación no cambia la información predictiva (AUROC idéntico 0.833). La ventaja es la estabilidad: β para '3+' = 2.815 con SE = 0.174 (vs 16.33 / 175.47). Este modelo es la referencia parsimoniosa para comparar con el Modelo 3.

Métricas de Ajuste

AIC	7,474
Devianza	7,458
LogLik	-3,729
vs Nulo (χ^2)	2,652 ***

Clasificación (umbral 0.5)


Exactitud	84.00%
Sensibilidad	37.75%
Especificidad	95.83%
AUROC	0.833

Nota: Modelos 1 y 2 no son anidados (distinta codificación de *NumOfProducts*). Solo contra el modelo nulo.








03 MODELO 2 — RECODIFICADO

$$\text{logit}(P) = \beta_0 + \beta_1 \text{Age} + \beta_2 \text{Gender} + \beta_3 \text{Geography} + \beta_4 \text{IsActiveMember} + \beta_5 \text{NumProducts_3M}$$

Linealidad: Age vs Logit (Modelo 2)



Linealidad: Balance vs Logit (Modelo 2)



$$\text{logit}(P) = \beta_0 + \beta_1\text{Age} + \beta_2\text{Age}^2 + \beta_3\text{Gender} + \beta_4\text{Geography} + \beta_5\text{IsActiveMember} + \beta_6\text{NumProducts_3M} \times \text{Balance_Zero}$$

Coeficientes y Odds Ratios			
Variable	β	OR	Sig.
Age (lineal)	0.344	1.411	***
Age ² (cuadrático)	−0.0029	0.997	***
Gender (Male)	−0.511	0.600	***
Geography (Germany)	0.872	2.392	***
Geography (Spain)	0.048	1.049	n.s.
IsActiveMember (Sí)	−0.983	0.374	***
NumProducts_3M 2	−0.979	0.376	***
NumProducts_3M 3+	4.037	56.67	***
Balance_Zero = Sí	0.800	2.226	***
NumProd.2 × Bal.Zero(Sí)	−1.758	0.172	***
NumProd.3+ × Bal.Zero(Sí)	−2.611	0.074	***

	Test stat	Pr(> Test stat)
Age	0.00	1
I(Age^2)	189.56	<2e-16 ***
Gender		
Geography		
IsActiveMember		
NumProducts_3M		
Balance_Zero		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1		


	GVIF	Df	GVIF^(1/(2*Df))
Age	45.763474	1	6.764871
I(Age^2)	45.924165	1	6.776737
Gender	1.002898	1	1.001448
Geography	1.262696	2	1.060046
IsActiveMember	1.066144	1	1.032543
NumProducts_3M	4.414154	2	1.449479
Balance_Zero	1.684169	1	1.297755
NumProducts_3M:Balance_Zero	5.924024	2	1.560106

Métricas de Ajuste	
AIC	7,082
Devianza	7,058
LogLik	−3,529
vs M3 sin Age ² (χ ²)	220.86 ***










03 MODELO 3 — FINAL

$$\text{logit}(P) = \beta_0 + \beta_1 \text{Age} + \beta_2 \text{Age}^2 + \beta_3 \text{Gender} + \beta_4 \text{Geography} + \beta_5 \text{IsActiveMember} + \beta_6 \text{NumProducts_3M} \times \text{Balance_Zero}$$

Linealidad: Age vs Logit (Modelo 3)



Distancia de Cook — Modelo 3



Variable	OR	Interpretación
Age ($\beta = 0.344$, $p < 0.001$)	1.411	Efecto lineal positivo. Cada año adicional incrementa el log-momio de abandono, con un pico a los ~59.3 años.
Age ² ($\beta = -0.0029$, $p < 0.001$)	0.997	El efecto marginal de la edad se frena y luego revierte pasados los ~59 años.
GenderMale ($\beta = -0.511$, $p < 0.001$)	0.600	Los hombres tienen momios de abandono ~41% menores que las mujeres (OR = 0.60).
GeographyGermany ($\beta = 0.872$, $p < 0.001$)	2.392	Los clientes alemanes tienen ~2.4 veces más momios de abandono que los franceses (categoría de referencia).
IsActiveMemberSí ($\beta = -0.983$, $p < 0.001$)	0.374	Los miembros activos tienen ~62% menos momios de abandono que los no activos.
NumProducts_3M2 ($\beta = -0.979$, $p < 0.001$)	0.376	Tener 2 productos reduce los momios en ~62.5% vs tener 1 producto (para clientes con saldo positivo).
NumProducts_3M3+ ($\beta = 3.979$, $p < 0.001$)	53.46	Los clientes con tres o más productos presentan momios de abandono aproximadamente 53.5 veces mayores que aquellos con un producto (entre clientes con saldo positivo).
Balance_ZeroSí ($\beta = 0.800$, $p < 0.001$)	2.226	Clientes con saldo = 0 y un producto tienen ~2.27 veces más momios de abandono que clientes con saldo positivo y un producto.
NumProducts_3M2 × Balance_ZeroSí ($\beta = -1.759$, $p < 0.001$)	OR combinado = 0.065	Entre los clientes con saldo igual a cero, aquellos que poseen dos productos equivale a una reducción cercana al 93.5% en los momios de abandono.
NumProducts_3M3+ × Balance_ZeroSí ($\beta = -2.611$, $p < 0.001$)	OR combinado = 4.16	Entre los clientes con saldo igual a cero, aquellos que poseen tres o más productos presentan momios de abandono aproximadamente 4.16 veces mayores que los clientes con saldo igual a cero y un solo producto.

| Validación general



Independencia

Cada registro = cliente distinto. Sin estructura temporal ni de panel. Supuesto asumido satisfecho.



Observaciones Influyentes

Distancia de Cook máxima: ~ 0.005 (M1/M2) y ~ 0.009 (M3). Muy por debajo de umbrales críticos (0.5 y 1). Estimaciones robustas.



Linealidad del Logit (Age)

Box-Tidwell: $\lambda = -0.175$, $t = -10.6$, $p < 0.001$. Desviación estadística pero sin curvatura pronunciada en la gráfica. Especificación cuadrática introducida.



Separación Completa (M1)


NumOfProducts=4 produce $\beta_8 = 16.33$ con $SE = 175.47$. Resuelto en M2 y M3 mediante recodificación en categoría '3+'.



Multicolinealidad (GVIF)

$GVIF^{(1/2 \cdot Df)} < 2.24$ en todos los términos de M1 y M2. En M3, la interacción arroja GVIF bruto=6.06 (esperado algebraicamente); GVIF ajustado=1.57 ✓

06 COMPARATIVA — CURVAS ROC



0.833

AUROC Modelo 1

0.833

AUROC Modelo 2

0.852

AUROC Modelo 3

Interpretación AUROC 0.852:

Si se seleccionan 2 clientes al azar (1 que abandona, 1 que permanece), el modelo asigna mayor probabilidad al que abandona en el 85.2% de los casos.

06 COMPARATIVA Y SELECCIÓN

Métrica	Modelo 1	Modelo 2	Modelo 3 ★	
Especificación	Base	NumProd recodif.	Age ² + Interacción	
Parámetros	9	8	12	
AIC	7,459	7,474	7,082 ✓	
Devianza	7,441	7,458	7,058 ✓	
LogLik	−3,720	−3,729	−3,529 ✓	
Exactitud	84.05%	84.00%	85.44% ✓	
Sensibilidad	38.00%	37.75%	43.45% ✓	
Especificidad	95.83%	95.83%	96.18% ✓	
Precisión (PPV)	69.98%	69.85%	74.43% ✓	
F1-Score	0.493	0.490	0.549 ✓	
AUROC	0.833	0.833	0.852 ✓	
Linealidad Age	No resuelta	No resuelta	Resuelta ✓	
Sep. completa	⚠ Presente	Resuelta	Resuelta	

Hallazgos, Conclusiones y Recomendaciones

Modelo seleccionado: Modelo 3 | AIC 7,082 · AUROC 0.852 · Sensibilidad 43.45% · F1 0.549

Hallazgos del Análisis

- La edad es el predictor más importante: el riesgo de abandono crece hasta los ~59 años y después desciende, revelando una dinámica no lineal.
- Los clientes alemanes tienen el doble de probabilidad de abandono que los franceses ($OR \approx 2.4$), sugiriendo condiciones de mercado o servicio diferenciadas.
- Las mujeres presentan un 41% más de odds de abandonar que los hombres, señal de un segmento con necesidades financieras posiblemente desatendidas.
- Los miembros inactivos tienen 3× más odds de abandono que los activos; la interacción con el banco es protectora.
- La interacción productos × saldo es la dimensión más reveladora: el perfil de máximo riesgo es saldo positivo con 3+ productos ($OR \approx 57$); el de menor riesgo es saldo positivo con 2 productos ($OR \approx 0.38$).
- Tener balance = 0 con 2 productos es el grupo de menor riesgo entre los de saldo nulo ($OR \approx 0.17$), lo que sugiere que esos clientes usan el banco como canal transaccional vinculado.

Recomendaciones

- Diseñar campañas de retención diferenciadas por edad: priorizar el segmento 50-65 años, donde el riesgo alcanza su punto máximo.
- Investigar y atender las causas del mayor churn en Alemania (calidad del servicio, oferta de productos, competencia local).
- Desarrollar programas de fidelización específicos para mujeres clientes, analizando qué productos o servicios incrementan su retención.
- Implementar alertas tempranas para clientes con 3+ productos y saldo positivo: este perfil tiene un riesgo desproporcionadamente alto que el modelo captura con $OR \approx 57$.
- Redefinir el umbral de clasificación por debajo de 0.5 si el objetivo de negocio es maximizar la detección de abandonos (a costa de más falsos positivos).
- Enriquecer el modelo futuro con variables de frecuencia de transacciones, NPS, historial de quejas y tiempo desde última interacción.

El Modelo 3 de regresión logística demuestra buena capacidad discriminante (AUROC 0.85) y supuestos estadísticos satisfechos. Los patrones identificados son accionables para estrategias de retención dirigidas.



Limitaciones y Extensiones

- Sin separación train/test — recomendable validación cruzada k-fold.
- Desbalance no tratado — explorar SMOTE o pesos de clase.
- Ajuste óptimo del umbral según costo de errores.

Conclusión Final

Mejor modelo:

Modelo 3 — menor AIC (7,082), mayor AUROC (0.852) y $F1 > 0.5$.

Factor clave:

La interacción NumProductos $\times$ Saldo revela dinámicas de negocio no capturadas en modelos simples.

Estrategia:

Priorizar retención en clientes alemanes mayores, inactivos y con portafolios de 3+ productos.

Validez:

Sin multicolinealidad, sin obs. influyentes y supuestos razonablemente satisfechos.